MACHINE LEARNING

UNDERGRADUATE HOMEWORK

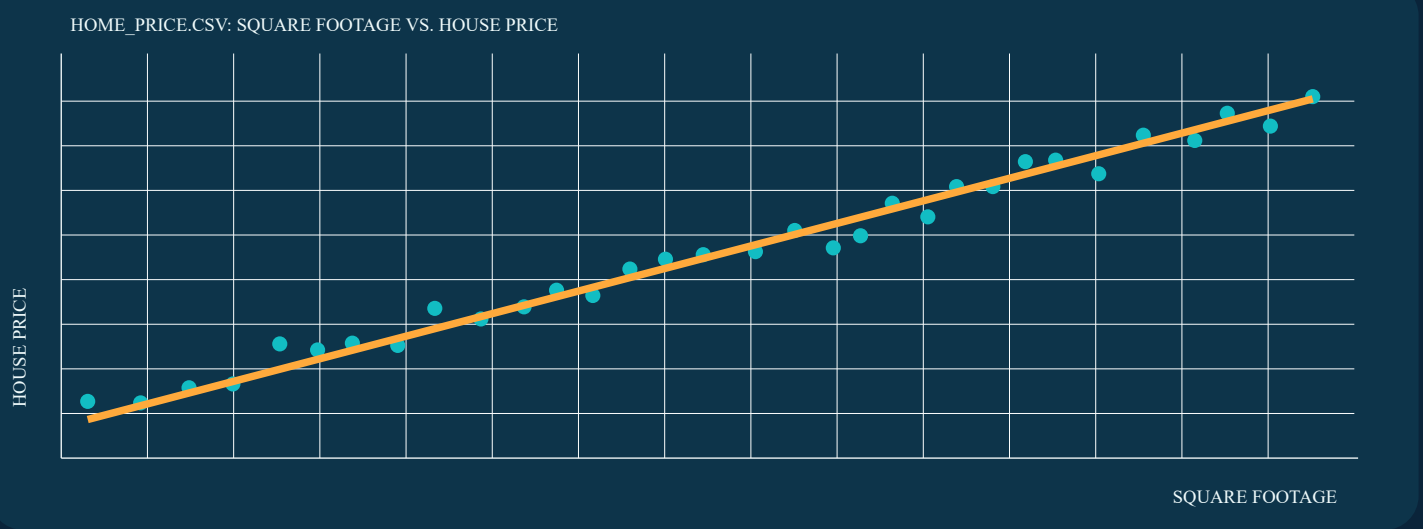
ASSIGNMENT

01

LINEAR REGRESSION

HOUSE PRICE PREDICTION

DATASET: Home_price.csv



SUPERVISOR
Dr. Fardin Akhlaghian Tab

TEACHING ASSISTANT
Mohammad Faraji

DEADLINE: 1405/09/01 | 11:59 PM

دانشگاه کردستان | مهندسی کامپیوتر

تمرین (+ پروژه)
رگرسیون خطی و چندگانه
Linear and Multi-Linear Regression | Home Price Prediction

ASSIGNMENT
1
100 + 20 PTS

دادهٔ تمرین — Home_price.csv

فایل Home_price.csv را بارگذاری کنید. ویژگی Square_Footage ورودی اصلی و ستون House_Price متغیر هدف است. تمام مراحل را در Jupyter Notebook انجام دهید و نتایج، نمودارها و تحلیل کوتاه را در قالب گزارش PDF ارائه کنید.

بخش اول: آشنایی با داده — 15 pts

سؤال 1 (5 pts) فایل CSV را با Pandas بارگذاری کنید؛ پنج ردیف نخست، ابعاد داده و نوع ستون‌ها را گزارش کنید.

سؤال 2 (6 pts) ستون‌های Square_Footage و House_Price را به‌ترتیب به‌عنوان ورودی و هدف انتخاب کنید. نمودار پراکندگی آن‌ها را رسم و رابطه را توصیف کنید.

سؤال 3 (4 pts) سایر ویژگی‌های موجود در مجموعه‌داده را نام ببرید.

بخش دوم: تقسیم داده‌ها — 20 pts

سؤال 4 (10 pts) با NumPy، بدون استفاده از train_test_split، داده‌ها را به‌صورت تصادفی با نسبت 80% برای مجموعهٔ آموزش[1] و 20% برای مجموعهٔ آزمون[2] تقسیم کنید. اندیس‌ها را حفظ کنید و از نبود هم‌پوشانی مطمئن شوید.

سؤال 5 (10 pts) با استفاده از train_test_split و random_state=42 داده‌ها را به مجموعهٔ آموزش و مجموعهٔ آزمون تقسیم کنید و تعداد نمونه‌های هر مجموعه را گزارش دهید.

بخش سوم: پیاده‌سازی دستی — 30 pts

سؤال 6 (15 pts) با استفاده از حلقه‌های پایتون، میانگین ویژگی ورودی و متغیر هدف را محاسبه کنید؛ سپس شیب و عرض از مبدأ خط رگرسیون را با فرمول‌های کمترین مربعات به دست آورید. برای محاسبهٔ ضرایب از هیچ تابع آماده‌ای استفاده نکنید.

سؤال 7 (10 pts) با مدل دستی، قیمت نمونه‌های مجموعهٔ آزمون را پیش‌بینی کنید؛ پنج مقدار واقعی و پیش‌بینی‌شده را گزارش و مقدار MSE آزمون را خودتان محاسبه کنید.

سؤال 8 (5 pts) نقاط واقعی مجموعهٔ آموزش و مجموعهٔ آزمون را با دو رنگ یا نشانگر متفاوت در یک نمودار پراکندگی نمایش دهید و خط رگرسیون محاسبه‌شده از داده‌های آموزش را روی همان نمودار رسم کنید. عنوان، برچسب محورها و راهنما را اضافه کنید.

بخش چهارم: پیاده‌سازی کتابخانه‌ای و مقایسه — 20 pts

سؤال 9 (20 pts) همین مسئله را با LinearRegression از کتابخانهٔ Scikit-learn و با همان اندیس‌های مجموعهٔ آموزش و مجموعهٔ آزمون پیاده‌سازی دستی حل کنید؛ ماتریس ویژگی‌های آموزش[3] و آزمون[4] و بردار هدف آموزش[5] و آزمون[6] را به‌ترتیب برای آموزش و ارزیابی مدل به کار ببرید. سپس ضرایب مدل، پیش‌بینی قیمت نمونه‌های آزمون و مقدار MSE را گزارش کنید.

بخش پنجم: تحلیل نتیجه — 15 pts

سؤال 10 (10 pts) یک مدل خطی سادهٔ جداگانه با ویژگی Year_Built و همان مجموعهٔ آموزش و مجموعهٔ آزمون آموزش دهید. مقدار MSE آن را با مدل Square_Footage مقایسه کنید.

سؤال 11 (5 pts) معنای شیب مدل اصلی را توضیح دهید. توضیح دهید چرا مدل اصلی تمرین در دستهٔ رگرسیون خطی ساده قرار می‌گیرد. دو محدودیت مدل تک‌ویژگی را برای پیش‌بینی قیمت خانه بنویسید.

سؤالات اختیاری — 20 BONUS PTS

سؤال تکمیلی 1 — +10 BONUS PTS

این بار دو ویژگی Square_Footage و Year_Built را هم‌زمان برای پیش‌بینی House_Price به کار ببرید. با Scikit-learn یک مدل رگرسیون خطی چندگانه (Multiple Linear Regression) آموزش دهید. ضرایب و مقدار MSE آزمون را گزارش و آن را با مدل تک‌ویژگی Square_Footage، با استفاده از همان مجموعهٔ آموزش و مجموعهٔ آزمون، مقایسه کنید. اثر افزودن ویژگی دوم را توضیح دهید.

سؤال تکمیلی 2 — +10 BONUS PTS

از وب‌سایت Kaggle یک مجموعه‌دادهٔ مناسب رگرسیون دانلود کنید و نام و لینک آن را بنویسید. با Scikit-learn دو مدل بسازید: Linear Regression با یک ویژگی ورودی و Multiple Linear Regression با دست‌کم دو ویژگی ورودی. با یک تقسیم train/test مشترک، هر دو مدل را آموزش دهید؛ مقادیر MSE و R^2 را روی داده‌های آزمون گزارش و عملکرد دو مدل را مقایسه کنید.

شیوهٔ تحویل: لطفاً فایل Jupyter Notebook (.ipynb) را با تمام سلول‌های اجراشده آماده کنید. همچنین، گزارشی منظم تهیه کنید که نتایج و نمودارهای مربوط به هر سؤال را به‌صورت جداگانه و مرتب ارائه دهد. سپس هر دو فایل را در یک فایل فشرده با نام زیر قرار دهید و ارسال کنید:

BL_MLE1_{student_name}_{Student_id}.zip

فایل فشرده را از طریق تلگرام به شناسهٔ @mohammaditt یا از طریق ایمیل به نشانی mohammad.faraji@uok.ac.ir ارسال کنید.

1. Training Set
2. Test Set
3. Training Feature Matrix (X_train)
4. Test Feature Matrix (X_test)
5. Training Target Vector (y_train)
6. Test Target Vector (y_test)